

Trabajo Práctico II

Filtros en SIMD

Organización del Computador II Primer Cuatrimestre de 2019

Integrante	LU	Correo electrónico
Sotomayor Marco	731/14	marco.soto1995@gmail.com
Tejera Walter	362/15	wtejerac@gmail.com



Facultad de Ciencias Exactas y Naturales Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja) Intendente Güiraldes 2160 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (54 11) 4576-3359 http://www.fcen.uba.ar

Índice

1.	Introducción	3
2.	Desarrrollo	3
	2.1. Imagen Fantasma	3
	2.1.1. Descripción	3
	2.1.2. Implementación	3
	2.2. Color Bordes	5
	2.2.1. Descripción	5
	2.2.2. Desarrollo	5
	2.3. ReforzarBrillo	6
	2.3.1. Descripción	6
	2.3.2. Implementación	6
3.	Resultados	7
	3.1. Planteo de hipótesis y experimentos	7
	3.1.1. Comparaciónes con C	7
	3.1.2. Desenrollado de ciclos en Imagen Fantasma	7
	3.1.3. Accesos a memoria en Reforzar Brillo	7
	3.2. Diseño de instancias y aspectos técnicos	8
	3.3. Experimentación	8
	3.3.1. Comparaciones	8
	3.3.2. Desenrollado de ciclos	11
	3.3.3. Accesos a memoria	11
4.	Conclusiones	12



1. Introducción

SIMD (single instruction, multiple data) es una arquitectura de computación centrada en el procesamiento simultaneo de una operación sobre varios datos mediante una única isntrucción. Tal técnica suele ser aplicada para trabajar de manera eficiente sobre vectores y matrices de datos.

El objetivo de este trabajo práctico es consolidar los conocimientos adquiridos en las clases sobre SIMD. Utilizando esta arquitectura implementaremos distintos algoritmos en ASM creando filtros sobre imágenes para luego comparar su rendimiento contra su implementación en C.

2. Desarrrollo

2.1. Imagen Fantasma

2.1.1. Descripción

Este filtro consiste en generar una imagen fantasma sobre la original, para ello se utiliza la misma imagen original al doble de tamaño y en escala de grises. Ademas se generara a partir de un punto cuyas coordenadas nos dan por parametro.

2.1.2. Implementación

En esta implementación se realizan dos recorridos diferentes por cada iteración sobre la matriz src:

- Uno de los recorridos es similar al implementado en C, es decir recorriendo todos los pixeles de cada fila. Con la principal diferencia de que se levantan 4 pixeles en vez de 1.
- En nuestra implementación no se calcula ii ni jj, en cambio existe un segundo recorrido que levanta los pixeles correspondientes a estos indices.

Recorrido de *ii* y *jj*:

Sabemos que $ii=i/2+offset_x$, $jj=j/2+offset_y$ representando "/" la división entera. Fijando el $offset_y$ en 0 veamos como cambia jj a partir de una sucesión de valores para j:

$$j = [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]$$
$$jj = [0, 0, 1, 1, 2, 2, 3, 3, 4, 4]$$

El valor de jj para los j impares es el mismo que para el par menor y mas cercano a ese j impar, ya que el operador "/" descarta el resto y devuelve solo el cociente es decir:

 $j=2*q \land j+1=2*q+r \Rightarrow j/2=q$ y (j+1)/2=q. Podemos usar esta información para afirmar que si $j=2*q \Rightarrow jj(j)==jj(j+1)$ (notar que en el calculo de jj, $offset_x$ es siempre la misma constante sumada, no cambia la igualdad).

Esto lo aprovechamos para no calcular ii ni jj en cada iteración, ya que i,j empiezan en $0 \Rightarrow ii = offset_y, jj = offset_x$. Luego basta con incrementar en 1 a ii o jj por cada 2 incrementos de i y j respectivamente (en nuestro caso los incrementos son de a 2 para jj y 4 para j ya que se procesan 4 pixeles).

Para calcular B, utilizamos una mascara que reordena las componentes de los 2 pixeles m[ii][jj] y m[ii][jj+1] de la siguiente manera: blue, green, red, green. Este nuevo orden permite que realicemos una suma horizontal, sin embargo no existe suma horizontal de a Byte, por lo que además extendemos con 0 cada byte usando la misma mascara.

$$pshufb = [G_1, R_1, G_1, B_1, G_0, R_0, G_0, B_0] \leftarrow \text{en words}$$

Una vez ordenadas las componentes se ejecutan 2 sumas horizontales para generar B_0 y B_1 en los dos words menos significativos del registro. Separamos los B en registros diferentes (R_{b0} , R_{b1}) y desempaquetamos a doublewords cada uno, además replicamos cada B en los 4 doubleword en su respectivo registro. Luego los convertimos en floats para dividirlos por 8 (b/4/2 == b/8).

Para procesar los pixeles, realizamos los siguiente pasos:

- Se mueven los 4 pixeles a 4 registros diferentes: R_{px0} , R_{px1} , R_{px2} y R_{px3} .
- En cada registro se realizan las conversiones necesarias para pasar de bytes a words y de words a doublewords para el pixel que le corresponda.
- Convertimos las componentes de cada registro a floats.
- Realizamos multiplicaciones vectoriales entre una constante con 4 datos de tipo float con valor 0,9 y cada uno de los R_{px} .
- Sumamos R_{px0} , R_{px1} con R_{b0} y R_{px2} , R_{px3} con R_{b1} .

Con esto tenemos nuestros 4 pixeles procesados. Por último queda realizar 4 conversiones de float con truncamiento a doubleword en R_{px0} , R_{px1} , R_{px2} y R_{px3} . Desempaquetamos (haciendo las conversiones intermedias) cada registro en 1 solo que junte los 4 pixeles procesados y lo guardamos en el destino.

Comentarios sobre el signado en operaciones: Algunas conversiones u operaciones no existen para números sin signo, esto puede generar problemas si lo números sin signo sobre los que se quiere operar son tan grandes que su representación binaria tiene el bit mas significativo en 1, pues en su interpretación signada serian negativos.

Los números mas grande sobre los que trabajamos son B y componente(px)*0,9+B/2. Si todas las componentes de m[ii][jj] valen $255 \Rightarrow B=4*255/4=255$. Luego $componente(px)*0,9+B/2 \simeq 230+126 \simeq 356$. Como todas las operaciones son realizadas luego de convertir los datos al menos a words tenemos los suficientes bits para representar 356 sin usar el bit mas significativo.

2.2. Color Bordes

2.2.1. Descripción

Color bordes modifica cada pixel operando mediante restas sobre los 8 pixeles que lo rodean, generando valores pequeños y similares para cada componente si los 8 pixeles tenían un color parecido entre ellos y variando estos valores en caso contrario. Esto genera diferentes componentes conexas con colores oscuros separadas por bordes de colores variables y claros. Además agrega un marco blanco de 1 pixel.

2.2.2. Desarrollo

La matriz se recorre de manera similar a la implementación en C, pero en cada iteración se modifican 2 pixeles. Utilizamos las herramientas de SIMD para levantar 3 filas $(i-1, i \ y \ i+1)$ de 4 pixeles, re ordenar los datos y luego operar. Nos referiremos a cada una de estas filas con mediante los nombres R_{i-1} , R_i y R_{i+1} . Llamaremos px0, px1, px2 y px3 a los pixeles de cada fila. Modificaremos px1 y px2 de R_i .

ii: Con el objetivo de realizar m[ii][j-1]-m[ii][j+1] mediante restas horizontales armamos 2 mascaras, una para procesar los datos de px1 y otra para px2. Esta mascara además extiende los datos de byte a words con ceros. A continuación mostraremos la mascara para procesar las operaciones de px1 y px2.

$$pshufb_{px1} = [0, 0, R_2, R_0, G_2, G_0, B_2, B_0] \leftarrow \text{en words}$$

$$R_{i} = [A_{3}, R_{3}, G_{3}, B_{3}, A_{2}, R_{2}, R_{2}, G_{2}, B_{2}, A_{1}, R_{1}, G_{1}, B_{1}, A_{0}, R_{0}, G_{0}, B_{0}]$$

$$indice = [0x0f, 0x0e, 0x0d, 0x0c, 0x0b, 0x0a, 0x09, 0x08, 0x07, 0x06, 0x05, 0x04, 0x03, 0x02, 0x01, 0x00]$$

$$mascara_{px2} = [0x80, 0x80, 0x80, 0x80, 0x80, 0x0E, 0x80, 0x06, 0x80, 0x0D, 0x80, 0x05, 0x80, 0x0C, 0x80, 0x04]$$

$$pshufb_{px2} = [0, 0, R_3, R_1, G_3, G_1, B_3, B_1] \leftarrow \text{en words}$$

Copiamos R_{i-1} , R_i y R_{i+1} en 3 registros, uno para cada uno, luego a los 3 originales aplicamos una mascara y a las 3 copias aplicamos la mascara restante. Teniendo los datos acomodados en 6 registros los siguientes pasos son directos y simples. Primero realizamos una resta horizontal en cada uno de ellos consiguiendo m[ii][j-1]-m[ii][j+1] de cada componente, luego aplicamos el valor absoluto y acumulamos los valores de cada componente.

- $\mathbf{j}\mathbf{j}$: En este caso primero operamos y luego reordenamos los datos. Esta vez nuestro iterador es jj y se mueve por j mientras que opera entre las filas i-1 e i+1. Queremos calcular m[i-1][jj]-m[i+1][jj] para cada componente.
 - Desempaquetamos R_{i-1} y R_{i+1} a words.
 - Restamos R_{i-1} y R_{i+1} desempaquetados.
 - Aplicamos valor absoluto a los resultados
 - A partir de este punto tenemos 2 registros R_1 y R_2 . R_1 contiene las restas en words de los componentes de j y j-1, mientras R_2 contiene las restas de j+2 y j+1.

- Para acumular estos resultados utilizo 1 registro intermedio para cada uno. Paso R_1 a R_3 y shifteo los resultados j a la parte mas baja de R_3 . Ahora el primer word de R_1 , R_2 y R_3 contienen los resultados de j-1, j+1 y j respectivamente.
- Sumamos los 3 registros y obtenemos las acumulaciones jj de las operaciones entre componentes para px1. Haciendo un proceso similar, pero con shifteos a la parte alta obtenemos las acumulaciones jj de px2.

Finalmente sumamos las acumulaciones ii y jj para px1 y px2, convertimos los resultados utilizando empaquetado saturado sin signo y lo guardamos en la imagen destino.

2.3. ReforzarBrillo

2.3.1. Descripción

Este filtro aumenta y disminuye el brillo de una imagen según el brillo que ya tenia. Sí el pixel supera un umbral, el brillo se aumenta, si el pixel esta debajo de un umbral, el brillo se disminuye. El efecto resultante es un refuerzo del brillo diferenciado.

2.3.2. Implementación

En este filtro consideramos varias cosas a la hora de implementarlo.

Para poder detenerminar si un pixel superaba o estaba por debajo de un umbral, necesitabamos hacer la siguiente cuenta:

$$b = (pixel.R + 2 * pixel.G + pixel.B) / 4$$

Seguido a esto, ya que cada componente de un pixel mide 1 byte, dando que el tamaño total de un pixel es de 4 bytes, en un registro xmm podemos levantar 4 pixeles. Sin embargo, si queremos que nuestra cuenta sea exacta, fue necesario extender el tamaño de cada componente a 2 bytes. Para esto, en vez de utilizar una instrucción de extension como **pmovzxbw**, decidimos utilizar la instrucción de pshufb con una mascara que nos dejá de la componente Verde en la posicion en la que deberia estar la transparencia. Quedando el registro xmm de la siguiente forma:

$$xmm = [G1 | R1 | G1 | B1 | G0 | R0 | G0 | B0]$$

Esto nos facilitó la suma, ya que solo tuvimos que usar la suma horizontal quedando el registro xmm:

$$xmm = [0 | 0 | 0 | 0 | G1 + R1 | G1 + B1 | G0 + R0 | G0 + B0]$$

y si usamos nuevamente la suma horizontal, obtendremos:

$$xmm = [\ 0 \ |\ 0 \ |\ 0 \ |\ 0 \ |\ 0 \ |\ R1 \ +\ 2 \times G1 \ +\ B1 \ |\ R0 \ +\ 2 \times G0 \ +\ B0\]$$

Finalmente dividimos por 4 usando un shift empaquetado de a word de 2 bits a derecha para que nos quede b, como nosotros queríamos.

Ahora, para poder compararlos con los umbrales que pueden ser numeros de hasta 4 bytes, es necesario extender nuevamente de word a dword (2 a 4 bytes) quedando los b de cada pixel expresados en dwords.

Una vez que tenemos nuestros b, pasamos a analizar cual b es mayor o menor a los umbrales pasados por parametro. Sabemos que como estamos preguntando por mayor o menor estrictos, no es posible que un b cumpla ambas condiciones al mismo tiempo, por lo que podemos evaluar al mismo tiempo ambas condiciones.

Luego aplicamos la mascara de brillo, tanto Superior como Inferior para así quedarnos con el brillo correspondiente en los valores que hayan cumplido la condición. Quedándonos de la siguiente forma.

```
xmmi = [0 \mid 0 \mid brilloSup para pixel 1 \mid brilloSup para pixel 0]
xmmj = [0 \mid 0 \mid brilloInf para pixel 1 \mid brilloInf para pixel 0]
```

Notemos que si existe el brilloInf para un pixel, no puede existir un brilloSup para el mismo pixel por lo anteriormente mencionado.

Finalmente para poder sumar o restar dichos brillos de forma consistente, empaquetaremos los brillos a word, saturando en caso de ser necesario.

Luego, aplicaremos un shuffle de words (tanto high como low), dejando cada uno en los lugares correspondientes para poder sumarlos. Previamente a esto desempaquetamos los pixeles originales a word para poder sumarlos o restarlos según corresponda. Los registros en donde tenemos los brillos quedaran de la siguiente forma:

```
xmmi = [ 0 | brilloSup1 | brilloSup1 | brilloSup1 | 0 | brilloSup0 | brilloSup0 | brilloSup0 ] xmmj = [ 0 | brilloInf1 | brilloInf1 | brilloInf1 | 0 | brilloInf0 | brilloInf0 | brilloInf0 ]
```

Luego sumamos o restamos según corresponda para que los pixeles nos queden de la siguiente forma:

```
xmmi = [ \ 0 \ | \ R1 + bSup1 \ | \ G1 + bSup1 \ | \ B1 + bSup1 \ | \ 0 \ | \ R0 \ bSup0 \ | \ G0 + bSup0 \ | \ B0 + bSup0 \ ]

xmmi = [ \ 0 \ | \ R1 - bInf1 \ | \ G1 - bInf1 \ | \ B1 - bInf1 \ | \ 0 \ | \ R0 \ bInf0 \ | \ G0 - bInf0 \ | \ B0 - bInf0 \ ]
```

Notar que podemos usar el mismo registro para sumar y restar por que los brillos $\neq 0$ están en posiciones distintas.

Una vez terminado este proceso, empaquetamos (de forma saturada) nuevamente para que nos queden los componentes de cada pixel en la parte mas baja del registro xmm, quedándonos de la siguiente forma:

```
xmmi = [ ... | nR1 | nG1 | nB1 | nR0 | nG0 | nB0 ]
Solo mostramos los 8 bytes mas bajos
```

Finalmente solo queda poner el quadword mas bajo de xmmi en la dirección a la que apunta rsi (que es mi iterador de la imagen destino).

3. Resultados

3.1. Planteo de hipótesis y experimentos

3.1.1. Comparaciónes con C

Con el objetivo de saber cual de las implementaciones es mas rápida compararemos los filtros hechos en ASM utilizando SIMD contra las implementaciones en C con diferentes niveles de optimizaciones. Utilizar SIMD nos permite reducir la cantidad de operaciones ya que se realizan en simultaneo, los accesos a memoria también se ven reducidos porque luego de cargar múltiples pixeles a un registro trabajamos entre registros sin volver a memoria. Creemos que los filtros implementados en ASM deben ser mas rápidos que la implementación en C incluso con sus optimizaciones pues utilizan muchos accesos a memoria y solo modifican un pixel por iteración.

3.1.2. Desenrollado de ciclos en Imagen Fantasma

Para este filtro desenrollaremos 10 ciclos procesando 40 pixeles por cada uno para luego comparar los resultados con su versión normal. Nuestra hipótesis era que desenrollar ciclos mejora el rendimiento disminuyendo los ticks de clock usados ya que hay menos overhead de ciclos (comparaciones, saltos) y menos predicción de saltos por parte del procesador.

3.1.3. Accesos a memoria en Reforzar Brillo

En este experimento, nos preguntamos cuanto nos cuesta cada acceso a memoria. Para dicho propósito, modificamos el algoritmo para que en cada iteración del ciclo, se traiga desde memoria cada mascara. Planteamos que a medida que vaya creciendo la imagen, el costo de usar el buffer de memoria va a pesar más y más ya que usar la memoria agrega una complejidad mucho mayor que hacer operaciones con registros.

3.2. Diseño de instancias y aspectos técnicos

Para los experimentos de comparación de rendimiento armamos instancias de imágenes cuyas resoluciones son múltiplo de $32 * i \times 18 * i$, $\forall i \in [1.,100]$.

La computadora en donde corrimos los experimentos cuenta con un procesador Intel Core I5-6200U, con 3MB de caché y 2,30GHz de frecuencia.

Para evitar valores atípicos corrimos 500 veces cada imagen en todos los experimentos. Además en el caso de los experimentos de desenrollado de ciclos y costo de accesos a memoria decidimos analizar las diferencias entre las medianas de la resolución de un filtro original y su modificación para tener una mejor visualización de los datos.

3.3. Experimentación

3.3.1. Comparaciones

Si observamos el gráfico de ASM en la figura 1 se puede apreciar un crecimiento recién en las instancias mas grandes, en cambio los gráficos de la implementación C presentan pendientes mas pronunciadas en todos sus puntos. Nuestra implementación supera ampliamente no solo a la optimización O2 de C si no también a O3, creemos que si bien manipular varios datos en simultaneo es muy ventajoso, poder realizar hasta 4 operaciones en punto flotante simplifica mucho el trabajo del procesador ya que estas operaciones son en particular muy costosas.

En la figura 2 la implementación también muestra una ventaja grande sobre las implementaciones optimizadas en C. Probablemente tenga que ver con los accesos a memoria y la cache. En el caso de C hay varios accesos a memoria distintos, en particular en el ciclo por filas causando que el primer acceso a memoria a cada fila potencialmente genere un miss en la cache, además este proceso se repite por cada pixel a modificar de la imagen. En cambio la implementación en ASM contiene 3 únicos accesos a memoria por iteración en donde se levantan 4 pixeles de 3 filas diferentes, todas las demás operaciones se realizan entre registros y se procesan 2 pixeles a la vez.

La figura 3 nos muestra que a diferencia de los otros filtros, la diferencia entre C y ASM es un poco mas chica. Creemos que esto se debe a que como solamente operamos con enteros, no hay una carga extra al operar con numero en punto flotante.

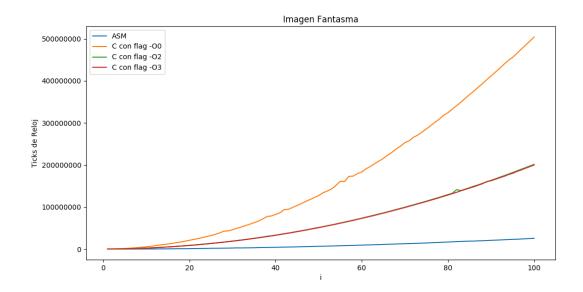


Figura 1: ImagenFantasma

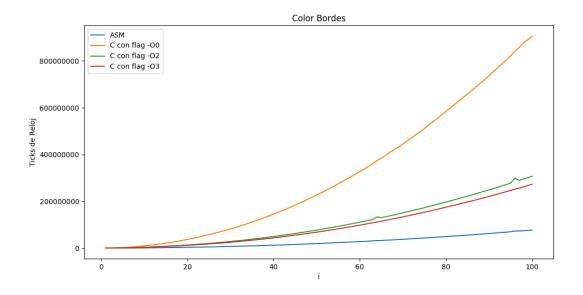


Figura 2: Color Bordes

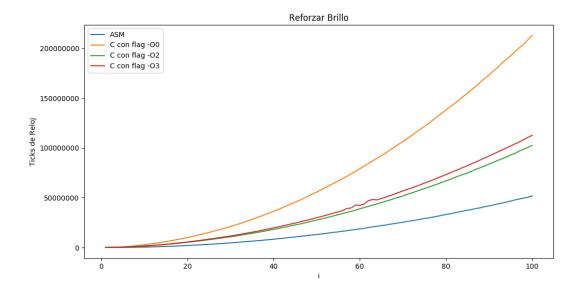


Figura 3: Reforzar Brillo

3.3.2. Desenrollado de ciclos



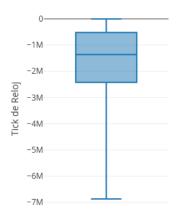


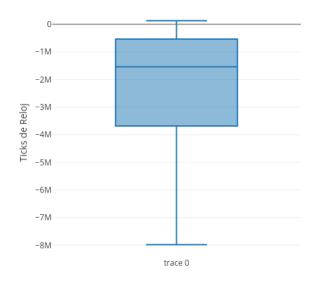
Figura 4: Diferencia de medianas entre Imagen fantasma con ciclos Desenrollados y el filtro original

Podemos observar que todos los valores se posicionan por debajo del 0. Los valores dentro del area Q1 y Q3 indican que el desenrollado de ciclos tiende a usar de 500000 a 2,5 millones de ticks de reloj menos, para ponerlo en perspectiva con i=100 el filtro sin modificar usa 25 millones de ticks, esto supone un ahorro del $10\,\%$ cuando se desenrollan 10 ciclos. Incluso los valores atípicos fueron a favor del filtro modificado.

3.3.3. Accesos a memoria

Como planteamos anteriormente, tomamos las medianas para cada resolución y nos fijamos las diferencias entre la implementación original (A) y la que tiene accesos a memoria en cada iteración (B).





Como podemos ver en el boxplot de diferencias, la mayoría de valores se encuentra por debajo de 0, lo que quiere decir que la implementación A corrió mas rápido con respecto a B. En algunos casos B fue efectivamente superior a A. En un vistazo mas cercano buscamos en la tabla de valores estos casos y solo se daban unos pocos con resoluciones muy chicas (i < 5). Creemos que al ser resoluciones tan chicas, hay menos misses en la cache ya que logramos recorrer la imagen en menos ciclos.

4. Conclusiones

En general pudimos corroborar nuestras hipótesis. La implementación en ASM usando las herramientas de SIMD provee un aprovechamiento de los recursos difícil de alcanzar sin entender el contexto del problema.

- Incluso con optimizaciones el código implementado en C era mucho mas lento que nuestra implementación en ASM
- Con el experimento de Desenrollado de ciclos pudimos observar como efectivamente el costo de la predicción de saltos y el overhead de ciclos influye sobre el rendimiento del algoritmo.
- Si bien para imágenes muy chicas el acceso a memoria puede no ser tan costoso, sigue siendo un limitante ya que como dijimos en su momento, usar el buffer de memoria puede llegar a condicionar toda la complejidad temporal de nuestro algoritmo.

SIMD es una excelente herramienta de bajo nivel para crear algoritmos que trabajan con vectores y matrices de datos, proporcionan un gran rendimiento comparado a implementaciones en lenguajes de alto nivel. Sin embargo este ahorro de complejidad en la ejecución se traspasa a la hora de producir código ya que resulta mucho mas difícil manipular varios datos simultáneamente y aumenta la cantidad de instrucciones.